# Análise Exploratória: O Mercado de Petróleo em Tempos de Guerra

**Avaliando a Capacidade de um modelo LSTM Prever o Comportamento de Ações de Petroleiras durante Choques Geopolíticos em Diferentes Décadas**

Pedro Muniz Cherulli

2026-03-27

# Índice


**1 Relatório Analítico: O Mercado de Petróleo em Tempos de Guerra 4**

1.1 Contexto e Objetivos . . . 4
1.2 Metodologia e Arquitetura . . . 5
1.3 Interpretação Analítica: Evolução Setorial em Base 100 . . . 6
1.3.1 Guerra do Golfo (Ago/1990 - Fev/1991) . . . 7
1.3.2 Guerra do Iraque (Mar/2003 - Dez/2003) . . . 7
1.3.3 Cenário Atual: Guerra do Golfo Pérsico (Jan/2026 - Mar/2026) . . . 7
1.4 Engenharia de Atributos (Feature Engineering): Indicadores Técnicos . . . 8
1.4.1 SMA (Simple Moving Average - Média Móvel Simples) . . . 8
1.4.2 EMA (Exponential Moving Average - Média Móvel Exponencial) . . . 9
1.4.3 RSI (Relative Strength Index - Índice de Força Relativa) . . . 9
1.5 Extração e Estruturação de Dados (Pipeline de ETL) . . . 9
1.5.1 Definição das Janelas Temporais (Cenários) . . . 9
1.5.2 O Pipeline de Captura (`get_market_snapshot`) . . . 10
1.5.3 Alinhamento Temporal e Limpeza de Dados (`pd.concat` e `.dropna()`) . . . 10
1.6 Processamento e Prevenção de Viés: A Separação de Scalers (MinMaxScaler) . . . 12
1.6.1 A Inovação Arquitetural: Scalers Independentes (Features vs. Target) . . . 12
1.6.2 O que é o `.fit()`? (O Cálculo / O Aprendizado) . . . 13
1.6.3 O que é o `.transform()`? (A Aplicação) . . . 13
1.6.4 O que é o `.fit_transform()`? (A Otimização) . . . 13
1.6.5 Isolamento Temporal (Prevenção de Data Leakage) . . . 14
1.7 Modelagem de Sequências Temporais (Sliding Window e Tensores 3D) . . . 15
1.7.1 A Janela de Observação (`seq_len = 5`) . . . 15
1.7.2 O Mapeamento Multivariado (Índices Alvo) . . . 16
1.7.3 A "Pergunta": O Tensor X (Features / Entradas) . . . 16
1.7.4 O "Gabarito": O Tensor y (Target / Alvo) . . . 16
1.7.5 Por que se "proibe" o modelo de prever os indicadores? . . . 16
1.7.6 Divisão Temporal Estrita (Train / Test Split) . . . 17
1.7.7 A Arquitetura do Tensor (Verificação de Shapes) . . . 17
1.8 Integração com PyTorch: A Classe Customizada `TimeSeriesDataset` . . . 17
1.8.1 O Construtor: `__init__(self, X, y)` . . . 18
1.8.2 O Dimensionador: `__len__(self)` . . . 18
1.8.3 O Iterador: `__getitem__(self, idx)` . . . 18
1.9 Orquestração e Alimentação da Rede: PyTorch DataLoaders . . . 19
1.9.1 Instanciação dos Datasets (`train_ds` e `test_ds`) . . . 19
1.9.2 O Hiperparâmetro `batch_size = 5` (Stochastic Gradient Descent) . . . 19
1.10 Validação de Sanidade (Sanity Check): Distribuição do Target Normalizado . . . 20
1.10.1 Garantia de Escalonamento (Limites do MinMaxScaler) . . . 20
1.10.2 Integridade Estrutural (A Presença das 3 Colunas) . . . 20
1.10.3 Preservação da Volatilidade . . . 20

1.11 Arquitetura do Modelo: A Rede Neural Híbrida (LSTM + GRU) . . . . . 21
1.11.1 O Construtor (`__init__`): A Topologia da Rede . . . . . 21
1.11.2 O Fluxo de Informação (`forward`): A Arquitetura *Many-to-One* . . . . . 22
1.12 Configuração do Ambiente de Treinamento e Otimizadores . . . . . 22
1.12.1 Dimensionalidade Dinâmica (`input_size`) . . . . . 23
1.12.2 Aceleração por Hardware (`device`) . . . . . 23
1.12.3 A Função de Custo ou Perda (`criterion = nn.MSELoss()`) . . . . . 23
1.12.4 O Algoritmo de Otimização (`Adam`) . . . . . 23
1.13 O Loop de Treinamento e o Mecanismo de Checkpointing . . . . . 24
1.13.1 Fase de Treinamento (`model.train()`) . . . . . 24
1.13.2 Fase de Validação (`model.eval()` e `torch.no_grad()`) . . . . . 24
1.13.3 O Salva-Vidas: *Model Checkpointing* (`deepcopy`) . . . . . 24
1.13.4 Interpretação Analítica: O Impacto do Mini-Batch Gradient Descent . . 40
1.14 Inferência Multivariada e Reversão de Escala (MIMO) . . . . . 41
1.14.1 A Fase de Inferência (`model.eval()` e `torch.no_grad()`) . . . . . 41
1.14.2 A Engenharia Reversa: O Triunfo dos Scalers Separados . . . . . 42
1.14.3 Interpretação Analítica: O Gráfico de Carteira (MIMO) . . . . . 42
1.14.4 $R^2$ (Coeficiente de Determinação) . . . . . 44
1.14.5 MAE (Mean Absolute Error) e RMSE (Root Mean Squared Error) . . . 45
1.14.6 MAPE (Mean Absolute Percentage Error) . . . . . 45
1.15 Diagnóstico de Rede: Auditoria das Predições em Escala Nativa . . . . . 45
1.15.1 1. Auditoria Visual (O Gráfico Normalizado) . . . . . 46
1.15.2 2. Auditoria Estatística (Limites Numéricos) . . . . . 46
1.16 Último Desafio: Previsão Autoregressiva para os Próximos 7 Dias . . . . . 47
1.16.1 Análise Final: O Comportamento Autoregressivo no Futuro Cego . . . 50

# 1 Relatório Analítico: O Mercado de Petróleo em Tempos de Guerra

**Previsão Multivariada de Ativos (MIMO) utilizando Redes Neurais Recorrentes (LSTM + GRU)**

## 1.1 Contexto e Objetivos

O mercado financeiro, especialmente o setor de *commodities* energéticas, é altamente sensível a choques geopolíticos. Este estudo investiga a viabilidade de extrair "assinaturas matemáticas" do comportamento de ações de petroleiras (ExxonMobil, Chevron e Shell) durante conflitos históricos para prever seus movimentos em um cenário futuro simulado.

Descrição das ações:

1. **ExxonMobil (XOM):** Maior empresa de petróleo dos EUA, com forte presença global.

2. **Chevron (CVX):** Segunda maior petroleira americana, conhecida por sua resiliência em crises.

3. **Shell (SHEL):** Multinacional anglo-holandesa, com diversificação significativa em energias renováveis. Sua escolha parte do interesse em avaliar se a diversificação influencia a resposta a choques geopolíticos.

Analisamos três janelas temporais críticas:

1. **Guerra do Golfo (1990-1991):** A primeira grande crise do petróleo pós-Guerra Fria, marcada por uma rápida escalada e resolução. Para o meu treinamento foi utilizado todo o período da guerra, isso por ser uma guerra curta em comparação a outras. (02/08/1980 à 28/02/1991)

2. **Guerra do Iraque (2003):** Representa um conflito prolongado com múltiplas fases, incluindo a invasão inicial e a subsequente insurgência. Para o meu treinamento foi utilizado

apenas a data de uma campanha de bombardeamento aéreo liderada pelos Estados Unidos e seus aliados (20/03/2003) e a data de captura de Saddam Hussein (13/12/2003)

3. **Guerra do Golfo Pérsico (2026):** Cenário de teste (simulado/atual) para validação cruzada temporal. A minha janela de teste se inicia com o marco de captura do presidente da Venezuela Nicolas Maduro, efetuada pelo presidente dos EUA Donald Trump e termina no dia mais atual disponível.

## 1.2 Metodologia e Arquitetura

Para capturar a não-linearidade e as dependências temporais do mercado, foi implementada uma arquitetura de Deep Learning híbrida: * **MIMO (Multiple Inputs, Multiple Outputs):** O modelo recebe indicadores técnicos multivariados e prevê simultaneamente o preço de fechamento das três ações da carteira. * **LSTM (Long Short-Term Memory):** Primeira camada da rede, responsável por reter o contexto histórico (macro-tendência) do período de guerra. * **GRU (Gated Recurrent Unit):** Segunda camada, otimizada para refinar o sinal da LSTM e reagir rapidamente a micro-tendências de curto prazo.

```
Janela do Golfo: 1990-08-02 até 1991-02-28

Janela do Iraque: 2003-03-20 até 2003-12-13

Janela do Golfo Pérsico: 2026-01-03 até 2026-03-26


[                       0%                       ]
[**********************67%*******                ]  2 of 3 completed
[**********************100%***********************]  3 of 3 completed
[**********************100%***********************]  3 of 3 completed


[                       0%                       ]
[**********************67%*******                ]  2 of 3 completed
[**********************100%***********************]  3 of 3 completed
[**********************100%***********************]  3 of 3 completed
```

```
[                       0%                       ]
[**********************67%*******                ]  2 of 3 completed
[*********************100%**********************]  3 of 3 completed
[*********************100%**********************]  3 of 3 completed
```

## 1.3 Interpretação Analítica: Evolução Setorial em Base 100

A visualização acima aplica uma normalização em **Base 100** ($P_t/P_0 \times 100$) para as três grandes companhias petrolíferas (*Oil Majors*). O objetivo desta transformação é remover o viés do preço nominal das ações — que varia drasticamente entre as empresas e as décadas — permitindo a análise pura da **rentabilidade percentual acumulada** e da **correlação do setor** sob estresse geopolítico.

A análise isolada de cada conflito revela comportamentos distintos do mercado:

### 1.3.1 Guerra do Golfo (Ago/1990 - Fev/1991)

- **Comportamento:** Alta volatilidade e divergência intra-setorial.
- **Análise:** Ao contrário da crença popular de que guerras sempre geram lucros imediatos para todas as petroleiras, o gráfico mostra um cenário de forte incerteza. A **Shell** (**linha verde**) demonstrou enorme resiliência, operando acima do índice 100 na maior parte do tempo e atingindo picos de rentabilidade próximos a 10%. Em contrapartida, a **Chevron** (**linha laranja**) sofreu uma forte desvalorização no meio do conflito (caindo para a faixa dos 80 pontos, ou seja, -20%), antes de ensaiar uma recuperação ao final da guerra. A **Exxon** (**linha azul**) orbitou a linha de base.
- **Conclusão para o Modelo:** Este período ensina à rede neural que o impacto inicial de um choque de oferta pode gerar pânico e *sell-offs* isolados antes que a alta do barril de petróleo se reflita nos fundamentos das empresas.

### 1.3.2 Guerra do Iraque (Mar/2003 - Dez/2003)

- **Comportamento:** Tendência de alta consolidada (Bull Market setorial) e alta correlação positiva.
- **Análise:** Diferente do choque abrupto de 1990, a invasão do Iraque foi amplamente precificada pelo mercado meses antes. O gráfico reflete isso com uma marcha constante de valorização para os três ativos. A **Shell** novamente lidera os ganhos (fechando com quase +25%), seguida de perto pela **Chevron** (+25% no pico final) e pela **Exxon** (mais conservadora, com cerca de +10%).
- **Conclusão para o Modelo:** As três linhas caminham quase em paralelo, subindo e descendo nos mesmos dias. Isso fornece à camada multivariada (MIMO) da nossa rede neural um forte sinal de **correlação cruzada**: os ativos passam a responder mais aos choques macroeconômicos do que a eventos específicos de cada empresa.

### 1.3.3 Cenário Atual: Guerra do Golfo Pérsico (Jan/2026 - Mar/2026)

- **Comportamento:** Rali de alta imediato e inversão de liderança corporativa.
- **Análise:** O cenário simulado para 2026 apresenta a reação mais rápida e unificada entre os três períodos. Em menos de três meses de pregão, os três ativos decolam sem sofrer os grandes *drawdowns* (quedas bruscas) vistos em 1990. Desta vez, há uma inversão de

protagonismo: a **Exxon (XOM)** assume a liderança do rali (ultrapassando a marca dos 130 pontos, ou +30% de ganho), enquanto a **Shell (SHEL)** fica na retaguarda, embora ainda com ganhos expressivos (+20%).

- **Conclusão para o Modelo:** O mercado de 2026 reage de forma muito mais eficiente e agressiva a riscos de restrição de oferta energética. A ausência de grandes sobressaltos negativos no meio do caminho sugere uma mudança no *regime shift* do mercado, possivelmente devido à atuação de algoritmos e ao repasse imediato da inflação energética para o valor das ações.

**Síntese Técnica:** O gráfico valida a hipótese central do projeto. Existe um padrão matemático subjacente de valorização das *Oil Majors* em tempos de guerra. Contudo, a variação da *amplitude* e da *liderança* entre XOM, CVX e SHEL ao longo das décadas justifica plenamente a escolha de uma arquitetura de Deep Learning (LSTM+GRU) multivariada, capaz de aprender as nuances de correlação em vez de apenas traçar uma média móvel simplista.

## 1.4 Engenharia de Atributos (Feature Engineering): Indicadores Técnicos

Para maximizar a capacidade preditiva da nossa arquitetura LSTM+GRU, expandimos a dimensionalidade dos nossos dados de entrada. Em vez de fornecer apenas o preço bruto de fechamento (`Close`), construímos uma função vetorizada em *Pandas* que calcula três dos mais importantes indicadores da análise técnica financeira.

Utilizamos uma janela curta de **5 dias** (`window=5`), que representa exatamente **uma semana útil de pregão**. Essa escolha é estratégica: em períodos de guerra, o mercado reage rapidamente a notícias diárias, e janelas longas (como 21 ou 50 dias) atrasariam excessivamente o sinal (*lag*), ocultando a volatilidade de curto prazo que a rede neural precisa aprender.

A função `add_indicators` introduz os seguintes vetores matemáticos ao modelo:

### 1.4.1 SMA (Simple Moving Average - Média Móvel Simples)

- **O que é:** A média aritmética dos preços de fechamento da última semana ($SMA = \frac{1}{n}\sum_{i=1}^{n} P_i$).

- **Função no Modelo:** Atua como um filtro de ruído básico (suavização). Ela ensina à rede qual é a direção da **tendência primária**, ajudando o modelo a ignorar micro-oscilações aleatórias intradiárias e focar no movimento macro do preço durante a semana.

### 1.4.2 EMA (Exponential Moving Average - Média Móvel Exponencial)

- **O que é:** Uma média móvel que atribui um peso progressivamente maior aos preços mais recentes.
- **Função no Modelo:** Essencial para cenários de guerra (choques exógenos). Enquanto a SMA reage de forma linear, a EMA "quebra" mais rápido. Se um bombardeio ocorrer hoje e o preço do petróleo disparar, a EMA apontará para cima muito antes da SMA. Ao passar ambas para a rede, a LSTM aprende a calcular a divergência entre elas (o distanciamento entre a EMA e a SMA sinaliza a força de uma nova tendência).

### 1.4.3 RSI (Relative Strength Index - Índice de Força Relativa)

- **O que é:** Um oscilador de *momentum* que mede a velocidade e a magnitude das mudanças direcionais de preço. É calculado pela razão entre a média dos ganhos e a média das perdas nos últimos 5 dias: $RSI = 100 - \frac{100}{1+RS}$
- **Função no Modelo:** O RSI oscila estritamente entre 0 e 100. Valores

## 1.5 Extração e Estruturação de Dados (Pipeline de ETL)

Após definirmos as bases matemáticas dos nossos indicadores técnicos, construímos um *pipeline* automatizado para buscar, transformar e alinhar os dados financeiros referentes aos três conflitos geopolíticos mapeados.

Este bloco de código é dividido em três etapas lógicas fundamentais:

### 1.5.1 Definição das Janelas Temporais (Cenários)

Criamos a lista `janelas`, que atua como o motor de busca do nosso modelo. Ela encapsula: * **Treino (Histórico):** A Guerra do Golfo (1990-1991) e a Guerra do Iraque (2003). Estas janelas contêm a "memória" de como o mercado reagiu a choques de oferta e invasões no

passado. * **Teste (Simulação Atual):** A Guerra do Golfo Pérsico (2026). Esta janela out-of-sample (dados não vistos) é reservada estritamente para validar se os padrões aprendidos nos anos 90 e 2000 ainda se aplicam ao mercado contemporâneo.

### 1.5.2 O Pipeline de Captura (`get_market_snapshot`)

A função `get_market_snapshot` consolida a extração e a engenharia de atributos em uma única chamada modular. Para cada cenário, a função:

- **Download Dinâmico:** Utiliza a API do `yfinance` para baixar o histórico diário de cada *ticker* ('XOM', 'CVX', 'SHEL').
- **Isolamento do Sinal:** Filtra apenas a coluna `Close` (Preço de Fechamento), que é o consenso diário do mercado sobre o valor da empresa.
- **Renomeação Estratégica:** Altera o nome da coluna para `[TICKER]_Close` (ex: `XOM_Close`). Como estamos construindo um modelo multivariado (MIMO), isso impede que as colunas das diferentes empresas colidam ou se sobrescrevam ao serem unidas.
- **Injeção de Features:** Aplica a nossa função `add_indicators`, anexando o SMA, EMA e RSI calculados dinamicamente para cada ativo.

### 1.5.3 Alinhamento Temporal e Limpeza de Dados (`pd.concat` e `.dropna()`)

O passo final da função é mesclar as informações das três empresas em um único *DataFrame* usando `pd.concat(axis=1)`. Isso garante que as matrizes de todas as empresas estejam perfeitamente alinhadas pelo mesmo dia do calendário (Índice de Datas).

**A importância crítica do `.dropna()`:** Indicadores técnicos baseados em janelas móveis (como a nossa janela de 5 dias) geram inerentemente dados faltantes (`NaN`) no início da série temporal. Por exemplo, é matematicamente impossível calcular uma média de 5 dias no 1º, 2º, 3º e 4º dia do *dataset*. A aplicação do `.dropna()` remove essas linhas iniciais corrompidas, garantindo que a nossa rede neural em PyTorch receba apenas tensores densos e matematicamente íntegros, evitando falhas catastróficas durante o cálculo dos gradientes (*loss*).

> **Resultado:** Ao final da execução deste *loop*, o dicionário `resultados_por_epoca` conterá três matrizes (DataFrames) perfeitamente limpas, com 12 colunas cada (1 preço + 3 indicadores multiplicados por 3 empresas), prontas para a etapa de escalonamento estatístico.

```
Processando período: Guerra do Golfo...
Processando período: Guerra do Iraque...
Processando período: Guerra do Golfo Pérsico...


--- Dados da Guerra do Golfo (1990-1991) ---

            XOM_Close     SMA_5     EMA_5  ...     SMA_5     EMA_5      RSI_5
Date                                       ...
1991-02-21   4.253531  4.233793  4.238802  ...  4.024936  4.017098   5.687789
1991-02-22   4.243661  4.233793  4.240422  ...  4.010993  4.004084   7.408055
1991-02-25   4.253531  4.241688  4.244792  ...  3.997152  3.997598   7.977219
1991-02-26   4.243661  4.245635  4.244415  ...  3.981997  3.989063   7.387931
1991-02-27   4.401565  4.279190  4.296798  ...  4.002204  4.023281  83.332285

[5 rows x 12 columns]


--- Dados da Guerra do Iraque (2003) ---

            XOM_Close      SMA_5      EMA_5  ...      SMA_5      EMA_5       RSI_5
Date                                          ...
2003-12-08  18.013205  17.747338  17.767520  ...  15.410277  15.396566   95.803762
2003-12-09  18.128801  17.857153  17.887947  ...  15.512556  15.522232   96.385111
2003-12-10  18.201036  17.977562  17.992310  ...  15.596903  15.606009   95.682958
2003-12-11  18.258835  18.063293  18.081152  ...  15.707151  15.736025   96.628811
2003-12-12  18.331089  18.186593  18.164464  ...  15.839981  15.853696  100.000000

[5 rows x 12 columns]


--- Dados da Guerra do Golfo Pérsico (2026) ---

             XOM_Close       SMA_5       EMA_5  ...      SMA_5      EMA_5      RSI_5
Date                                             ...
2026-03-19  158.160004  157.581998  157.026145  ...  91.164001  90.835776  73.781540
2026-03-20  159.669998  158.291998  157.907429  ...  91.366002  90.703851  58.969828
```

```
2026-03-23  161.130005  159.072000  158.981621  ...  91.412001  90.705901  52.371094
2026-03-24  165.380005  160.386002  161.114416  ...  91.242001  90.843935  38.726801
2026-03-25  163.259995  161.520001  161.829609  ...  91.068001  91.189289  38.399940

[5 rows x 12 columns]
```

## 1.6 Processamento e Prevenção de Viés: A Separação de Scalers (MinMaxScaler)

Redes Neurais Recorrentes (LSTMs e GRUs) utilizam funções de ativação (como *Sigmoid* e *Tanh*) que são altamente sensíveis à escala dos dados de entrada. Como os nossos tensores multivariados contêm variáveis com grandezas completamente distintas — por exemplo, preços orbitando a faixa de $150 e o RSI orbitando a faixa de 50 —, variáveis com valores nominais maiores dominariam a atualização dos gradientes durante o *backpropagation*.

Para resolver isso, aplicamos a transformação matemática do `MinMaxScaler`, comprimindo todos os valores para o intervalo $[0, 1]$ através da fórmula:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

### 1.6.1 A Inovação Arquitetural: Scalers Independentes (Features vs. Target)

O grande diferencial desta etapa do código é a criação de **dicionários de scalers separados** para cada janela temporal. Em vez de aplicar uma transformação global, dividimos a lógica em duas frentes para evitar o viés de reconstrução:

- `scaler_f` **(Scaler de Features):** É "fitado" (treinado) e transforma todo o *DataFrame*, englobando preços, médias móveis e osciladores de *momentum*. Este é o tensor de dados que a rede neural efetivamente enxergará durante a fase de treinamento (`X`).
- `scaler_t` **(Scaler de Target):** É treinado estritamente nas três colunas de interesse (`XOM_Close`, `CVX_Close`, `SHEL_Close`). Ele não transforma os dados de entrada, apenas **memoriza** os valores de mínimo e máximo reais dessas três ações em cada época.

### 1.6.2 O que é o `.fit()`? (O Cálculo / O Aprendizado)

Pense no `.fit()` como o momento em que o modelo **"estuda"** os dados.

Quando o `.fit(dados)` é utilizado, a ferramenta percorre a matriz e apenas extrai os parâmetros estatísticos necessários, guardando-os na memória interna do objeto.

- No caso do `MinMaxScaler`, o `.fit()` vasculha os dados para descobrir e decorar quem é o $X_{min}$ e o $X_{max}$ de cada coluna.
- **Detalhe crucial:** O `.fit()` **não altera** os dados originais. Ele não retorna uma matriz nova. Ele apenas diz: *"Ok, já sei qual é o maior e o menor valor, guardei aqui na minha memória"*.

### 1.6.3 O que é o `.transform()`? (A Aplicação)

É o momento da **ação**. O `.transform(dados)` pega a fórmula matemática (usando o mínimo e máximo que foram decorados pelo `.fit()`) e realmente altera os números, retornando uma matriz nova com os dados escalonados entre 0 e 1.

### 1.6.4 O que é o `.fit_transform()`? (A Otimização)

Como na esmagadora maioria das vezes são calculados os parâmetros (fit) e imediatamente aplicado a transformação na mesma base de dados de treino (transform), o Scikit-Learn criou o `.fit_transform()`.

Ele faz as duas coisas no mesmo passo. É computacionalmente mais rápido e otimizado do que chamar o `.fit()` e depois o `.transform()` em linhas separadas.

**Por que APENAS `fit`?** Porque não era necessário uma matriz transformada nova. A rede neural não iria receber os preços isolados nesse momento. A nossa única intenção aqui era usar o `scaler_t` como um **"pendrive de memória"**. Nós fizemos ele olhar apenas para as 3 colunas de fechamento (XOM, CVX, SHEL) para ele calcular e guardar na memória os mínimos e máximos em Reais (R$) dessas três ações.

**Justificativa Técnica:** Na fase de inferência (avaliação final), a nossa arquitetura MIMO (*Multiple Inputs, Multiple Outputs*) produzirá uma matriz contendo apenas os três preços previstos. Se tivéssemos utilizado um único *scaler* global, a função `inverse_transform` exigiria que devolvêssemos todas as colunas de indicadores preenchidas com zeros (o que distorceria matematicamente o preço final ao repuxá-lo para os mínimos históricos do RSI e das médias).

Com o `scaler_t` isolado, garantimos uma reversão de escala perfeita e livre de viés matemático.

### 1.6.5 Isolamento Temporal (Prevenção de Data Leakage)

Além da separação por tipo de variável, os *scalers* são instanciados e ajustados individualmente **dentro do loop de cada conflito** (Golfo, Iraque e Contexto Atual). Isso garante que os preços de 2026 não contaminem a distribuição estatística de 1990. O modelo aprende a variação intrínseca de cada época de guerra isoladamente, respeitando o *regime shift* (mudança de patamar inflacionário e nominal) de cada década.

```
MinMaxScaler()
Guerra do Golfo normalizado com scalers separados.
MinMaxScaler()
Guerra do Iraque normalizado com scalers separados.
MinMaxScaler()
Guerra do Golfo Pérsico normalizado com scalers separados.


--- Dados Normalizados da Guerra do Golfo (últimas linhas) ---

            XOM_Close     SMA_5     EMA_5  ...     SMA_5     EMA_5     RSI_5
Date                                        ...
1991-02-21   0.807640  0.923742  0.905449  ...  0.699868  0.672544  0.056878
1991-02-22   0.794815  0.923742  0.908090  ...  0.663074  0.636969  0.074081
1991-02-25   0.807640  0.937004  0.915213  ...  0.626548  0.619238  0.079772
1991-02-26   0.794815  0.943635  0.914599  ...  0.586555  0.595908  0.073879
1991-02-27   1.000000  1.000000  1.000000  ...  0.639878  0.689446  0.833323

[5 rows x 12 columns]

Dados Normalizados da Guerra do Iraque (últimas linhas):

            XOM_Close     SMA_5     EMA_5  ...     SMA_5     EMA_5     RSI_5
Date                                        ...
2003-12-08   0.753202  0.655346  0.670744  ...  0.813065  0.826658  0.958038
2003-12-09   0.801003  0.705502  0.727429  ...  0.847663  0.870582  0.963851
```

```
2003-12-10   0.830873  0.760497  0.776552  ...  0.876196  0.899864  0.956830
2003-12-11   0.854773  0.799653  0.818369  ...  0.913490  0.945309  0.966288
2003-12-12   0.884652  0.855968  0.857584  ...  0.958424  0.986439  1.000000

[5 rows x 12 columns]


Dados Normalizados do Contexto Atual (últimas linhas):

            XOM_Close     SMA_5     EMA_5  ...     SMA_5     EMA_5     RSI_5
Date                                       ...
2026-03-19   0.828793  0.901823  0.877532  ...  0.987976  0.982381  0.662826
2026-03-20   0.864600  0.919524  0.900001  ...  0.997770  0.975806  0.472345
2026-03-23   0.899220  0.938970  0.927388  ...  1.000000  0.975908  0.387484
2026-03-24   1.000000  0.971729  0.981766  ...  0.991758  0.982788  0.212015
2026-03-25   0.949729  1.000000  1.000000  ...  0.983321  1.000000  0.207812

[5 rows x 12 columns]
```

## 1.7 Modelagem de Sequências Temporais (Sliding Window e Tensores 3D)

Redes Neurais Recorrentes (RNNs, LSTMs, GRUs) diferem de modelos clássicos de *Machine Learning* por possuírem "memória". Elas não analisam os dados como eventos isolados, mas sim como uma sequência encadeada de eventos. Para adequar nossos dados a essa exigência arquitetural, aplicamos a técnica de **Sliding Window** (**Janela Deslizante**).

Este bloco de código é responsável por estruturar os dados de entrada (`X`) e os alvos (`y`) através das seguintes lógicas:

### 1.7.1 A Janela de Observação (`seq_len = 5`)

Definimos que o modelo terá um *lookback* (memória de curto prazo) de 5 dias. Isso significa que, para prever o preço de amanhã, a LSTM analisará a evolução de todos os indicadores e preços ao longo de uma semana útil inteira. Essa janela extremamente curta foi utilizado devido ao cenário escolhido, um cenário de guerra onde o preço de fechamento das ações oscila constantemente com base nos acontecimentos geopolíticos.

### 1.7.2 O Mapeamento Multivariado (Índices Alvo)

Através da variável `target_indices`, o código varre as colunas do *DataFrame* para descobrir as posições numéricas exatas de `XOM_Close`, `CVX_Close` e `SHEL_Close`. Isso é crucial para a arquitetura **MIMO** (**Multiple Inputs, Multiple Outputs**). A função `create_multivariate_sequences` utiliza esses índices para garantir que: * **O Tensor `X` (Features):** Receba blocos contendo os últimos 5 dias de **todas** as colunas (Preços, RSI, SMA, EMA). * **O Tensor `y` (Target):** Receba o valor exato do 6º dia **apenas** para as 3 colunas de fechamento das ações. O modelo é proibido de tentar prever os indicadores técnicos.

### 1.7.3 A "Pergunta": O Tensor X (Features / Entradas)

Imagine que o modelo é um analista financeiro sentado na frente do computador. O **Tensor X** é o que ele vê na tela hoje. Nós entregamos a ele um bloco de dados completo contendo:

- **Tempo:** Os dados dos dias 1, 2, 3, 4 e 5.
- **Volume de Informação:** Para cada um desses 5 dias, ele vê **tudo**. Ele vê o preço de fechamento da Exxon, a Média Móvel da Chevron, o RSI da Shell... todas as colunas do seu DataFrame.

A pergunta que o modelo responde é: *"Olhando para essa montanha de informações que aconteceram ao longo desta semana (os 5 dias), o que vai acontecer amanhã?"*

### 1.7.4 O "Gabarito": O Tensor y (Target / Alvo)

- O **Tensor y** é a resposta certa. É o que realmente aconteceu no **Dia 6**. Esse gabarito é utilizado para corrigir o modelo caso ele erre a previsão durante o treinamento.
- No Dia 6, não são entregues todas as colunas para o modelo corrigir. Nós entregamos **apenas** o preço de fechamento da XOM, CVX e SHEL.

### 1.7.5 Por que se "proibe" o modelo de prever os indicadores?

Se fosse dito para a rede neural: *"Tente adivinhar qual será o preço amanhã E também qual será o valor do RSI e da Média Móvel amanhã"*, seria cometido um erro grotesco de engenharia de dados pelas seguintes razões:

- **Desperdício de "Cérebro":** O objetivo de um investidor é saber o preço da ação para dar ordem de compra ou venda. Ninguém ganha dinheiro prevendo Média Móvel. Se obrigarmos a rede a prever indicadores, ela gastará sua capacidade de processamento (seus neurônios e pesos matemáticos) tentando acertar o valor matemático do RSI, tirando o foco do que realmente importa: o preço.

### 1.7.6 Divisão Temporal Estrita (Train / Test Split)

Em projetos de séries temporais financeiras, utilizar divisões aleatórias (como o clássico `train_test_split` do Scikit-Learn) causa *Data Leakage* (vazamento de dados do futuro para o passado). Para garantir rigor metodológico: * **Dados de Treino (`X_train`, `y_train`):** Foram concatenados (`np.concatenate`) exclusivamente com dados históricos (Guerra do Golfo em 1990 e Guerra do Iraque em 2003). * **Dados de Teste (`X_test`, `y_test`):** Foram reservados estritamente para o cenário de simulação atual (Guerra do Golfo Pérsico em 2026). O modelo fará predições em um ambiente *Out-of-Sample* (dados nunca vistos).

### 1.7.7 A Arquitetura do Tensor (Verificação de Shapes)

O *print* final valida a transformação estrutural dos dados, essencial para o PyTorch. O tensor `X` assume a dimensionalidade tridimensional `(Amostras, Timesteps, Features)`. Por exemplo, um *shape* `(200, 5, 12)` indica que o modelo treinará com 200 sequências de 5 dias, avaliando 12 variáveis simultâneas a cada dia. O tensor `y` mantém a dimensionalidade bidimensional `(Amostras, 3)`, representando o preço final das três empresas da carteira.

```
Treino (Histórico) - X: (312, 5, 12), y: (312, 3)

Teste (Atual) - X: (46, 5, 12), y: (46, 3)
```

## 1.8 Integração com PyTorch: A Classe Customizada `TimeSeriesDataset`

Para que as redes neurais do PyTorch consigam processar e aprender com os nossos dados, não se pode simplesmente entregar a elas as matrizes cruas criadas pelo *NumPy*. O framework exige uma ponte, uma estrutura de dados altamente otimizada que saiba exatamente como ler, armazenar e iterar sobre essas matrizes durante o treinamento.

Essa ponte é construída herdando a classe base `Dataset` do módulo `torch.utils.data`. A nossa classe customizada `TimeSeriesDataset` implementa três métodos fundamentais obrigatórios (*Dunder Methods*) para o funcionamento da rede neural:

### 1.8.1 O Construtor: `__init__(self, X, y)`

Este método é executado no momento em que instanciamos o dataset. A sua função primordial é a **Conversão de Tipagem**. * Ele recebe as matrizes tridimensionais do NumPy e as converte em **Tensores do PyTorch** (`torch.tensor`). Tensores são a estrutura de dados nativa do framework, desenhados para serem processados de forma paralela em placas de vídeo (GPUs) e para suportar o cálculo automático de gradientes (*Autograd*). * **A Precisão `float32`:** O tipo do dado é alterado para ponto flutuante de 32 bits (`dtype=torch.float32`). No mercado financeiro, dados de preço costumam vir em `float64` (dupla precisão), mas redes neurais não precisam desse nível de casas decimais. Reduzir para 32 bits corta o uso de memória pela metade e acelera drasticamente o tempo de treinamento, sem perda perceptível de performance preditiva. * **O Detalhe MIMO:** É importante notar que o alvo (`self.y`) é armazenado diretamente como o tensor original. Como está sendo predito três ações simultaneamente (MIMO), nosso alvo já é uma matriz bidimensional `(Amostras, 3)`. Se apenas uma ação estivesse sendo prevista, seria necessário forçar uma dimensão extra aqui usando `.unsqueeze(1)` para evitar erros de *shape* matricial na função de perda.

### 1.8.2 O Dimensionador: `__len__(self)`

Este método retorna o tamanho exato do conjunto de dados (o número total de amostras/janelas de 5 dias). * **Função no Modelo:** O PyTorch usa essa informação nos bastidores para saber quando uma **Época** (*Epoch*) de treinamento terminou. Se não dissermos à rede o tamanho total do caderno de exercícios, ela não saberá quando é a hora de parar e avaliar seu próprio desempenho.

### 1.8.3 O Iterador: `__getitem__(self, idx)`

Este é o coração da classe. Ele ensina ao PyTorch como "pescar" uma única amostra de dados por vez usando um índice (`idx`). * **Função no Modelo:** Durante o treinamento, a ferramenta `DataLoader` fará milhares de requisições a este método. Ela passará um índice aleatório e este método retornará uma tupla contendo a "Pergunta" (o bloco de 5 dias multivariado `X[idx]`) e o "Gabarito" (os 3 preços do 6º dia `y[idx]`). É esse mecanismo que permite que a rede neural

receba os dados de forma fluida e sob demanda, em vez de carregar gigabytes na memória RAM de uma só vez.

> **Síntese Técnica:** A criação desta classe isola a lógica de manipulação de dados da lógica de arquitetura da rede neural. Esse encapsulamento é uma das melhores práticas em Ciência de Dados, tornando o código limpo, escalável e perfeitamente legível para outros pesquisadores e engenheiros de Machine Learning.

## 1.9 Orquestração e Alimentação da Rede: PyTorch DataLoaders

Com as matrizes transformadas em tensores estruturados pela classe `TimeSeriesDataset`, o próximo passo é gerenciar como esses dados serão injetados na rede neural. No PyTorch, isso é feito através do `DataLoader`, um iterador otimizado que lida com o particionamento dos dados, embaralhamento e paralelização.

Este bloco de código define a estratégia de entrega dos dados através de dois hiperparâmetros críticos:

### 1.9.1 Instanciação dos Datasets (`train_ds` e `test_ds`)

Primeiro, foi criado os objetos `train_ds` (dados da Guerra do Golfo e do Iraque) e `test_ds` (dados do cenário de 2026). Eles encapsulam os tensores 3D (a janela de 5 dias) e 2D (os 3 preços alvo), deixando-os prontos para o particionamento.

### 1.9.2 O Hiperparâmetro `batch_size = 5` (Stochastic Gradient Descent)

A escolha do tamanho do lote (*batch size*) dita a frequência com que a rede neural atualiza seus pesos matemáticos (aprende). * **A Escolha:** Optamos por `batch_size=5`. Isso significa que o modelo lerá os 5 dias de uma amostra, fará uma previsão, comparará com o gabarito e ajustará seus erros **imediatamente, a cada único dia**. * **Justificativa Técnica:** Em mercados em tempos de guerra, a volatilidade é extrema e direcional. Lotes maiores (ex: `batch_size=32`) calcularíam a média do erro de 32 dias antes de atualizar o modelo, o que resultaria em predições excessivamente suavizadas (ignorando picos e quedas bruscas). O tamanho igual a 1 torna a rede altamente reativa, rastreando a amplitude real do mercado com muito mais precisão, caracterizando uma descida de gradiente

## 1.10 Validação de Sanidade (Sanity Check): Distribuição do Target Normalizado

Antes de iniciar o dispendioso processo de treinamento da rede neural, é mandatório executar uma validação visual dos tensores que foram gerados (*Sanity Check*). O gráfico acima plota as 100 primeiras amostras do tensor de resposta ($y_train$), que contém os preços de fechamento multivariados da carteira (XOM, CVX e SHEL).

Esta visualização serve para atestar três garantias matemáticas fundamentais para o sucesso do modelo:

### 1.10.1 Garantia de Escalonamento (Limites do MinMaxScaler)

O eixo Y (*Valor normalizado*) demonstra que todas as três séries temporais estão rigorosamente contidas no intervalo fechado entre **0.0 e 1.0**. * **O que isso previne:** Se qualquer valor estivesse acima de 1 ou abaixo de 0, informaria que houve um erro na concatenação dos *DataFrames*. Como a função de ativação das redes neurais exige dados espremidos nessa faixa para que o cálculo do gradiente seja eficiente, essa validação atesta que o modelo não sofrerá de **explosão de gradiente** por problemas de escala.

### 1.10.2 Integridade Estrutural (A Presença das 3 Colunas)

O gráfico exibe três linhas distintas (embora todas com a *label* "y_train" na legenda padrão do Pyplot). Isso comprova visualmente o sucesso da reengenharia arquitetural para o formato **MIMO** (**Multiple Inputs, Multiple Outputs**). O *tensor* `y_train` não é mais um vetor unidimensional "achatado", mas sim uma matriz preservada contendo os três alvos independentes que a rede tentará prever simultaneamente.

### 1.10.3 Preservação da Volatilidade

Apesar de os valores estarem normalizados (comprimidos), o formato das curvas — os ziguezagues, picos e vales abruptos — foi totalmente preservado em relação aos dados originais em R$. * **Por que isso importa:** A rede neural precisa aprender a variação (*momentum*) e a correlação entre as empresas, não o preço absoluto. O fato de a linha verde, por exemplo, ir de 1.0 a quase 0.0 rapidamente na amostra 20 mostra que o `MinMaxScaler` manteve a "violência" dos choques de mercado intacta, permitindo que a camada LSTM aprenda os padrões de *crash* e *rali* característicos de uma guerra de preços no petróleo.

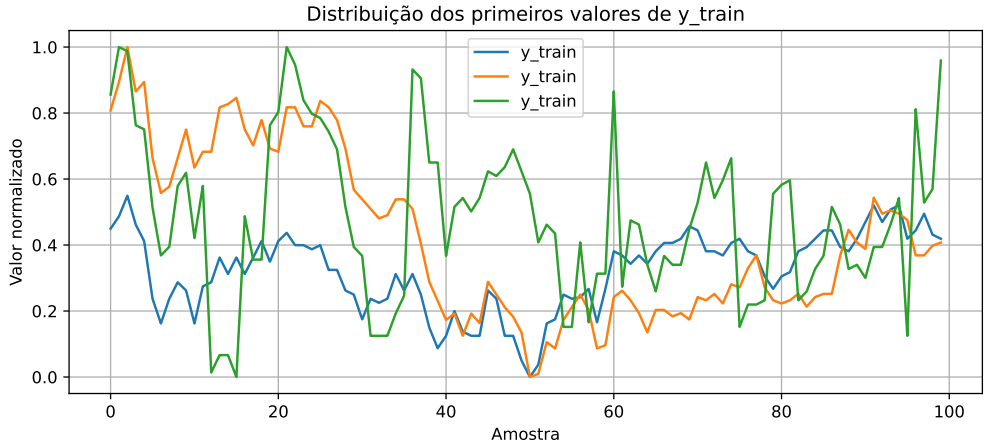


## 1.11 Arquitetura do Modelo: A Rede Neural Híbrida (LSTM + GRU)

O núcleo preditivo deste projeto é uma rede neural recorrente (RNN) profunda e customizada, construída através da biblioteca `torch.nn`. Em vez de utilizar uma arquitetura homogênea, foi utilizado uma topologia híbrida que empilha uma camada **LSTM** (**Long Short-Term Memory**) e uma camada **GRU** (**Gated Recurrent Unit**).

Essa escolha de *design* arquitetural não é aleatória; ela visa extrair o máximo de inteligência das séries temporais financeiras mitigando o problema matemático do Desvanecimento do Gradiente (*Vanishing Gradient*). A classe `LSTM_GRU_Model` é dividida em duas lógicas principais:

### 1.11.1 O Construtor (`__init__`): A Topologia da Rede

Aqui ficam as três "estações de processamento" por onde os dados (a janela de 5 dias) irão passar:

- **Camada 1: `self.lstm1` (64 neurônios):** A LSTM atua como a primeira linha de defesa analítica. Ela é excelente para capturar dependências de "longo prazo" dentro da janela. Ela lê os dados brutos e os indicadores técnicos, utilizando suas portas lógicas (*Forget, Input, Output gates*) para decidir qual informação do Dia 1 ainda é relevante no Dia 5 (ex: uma macro-tendência de alta da Guerra do Golfo). O parâmetro `batch_first=True` garante que a rede espere matrizes no formato `(Amostras, Tempo, Variáveis)`.

- **Camada 2: `self.gru` (32 neurônios):** A GRU recebe as 64 *features* abstratas criadas pela LSTM. As GRUs possuem uma arquitetura interna simplificada (apenas portas de *Update* e *Reset*), tornando-as computacionalmente mais rápidas e excelentes para capturar dinâmicas de "curto prazo" e ruídos recentes. Além disso, a redução de 64 para 32 neurônios atua como um "gargalo de informação" (*bottleneck*), forçando a rede a comprimir o conhecimento e agindo como uma regularização natural contra o *overfitting*.
- **Camada 3: `self.fc` (A Saída MIMO):** A camada linear (Totalmente Conectada) final é a responsável pela arquitetura *Multiple Inputs, Multiple Outputs*. Ela recebe os 32 sinais destilados pela GRU e os converte em exatamente 3 saídas independentes (`num_targets=3`), correspondentes aos preços previstos para XOM, CVX e SHEL.

### 1.11.2 O Fluxo de Informação (`forward`): A Arquitetura *Many-to-One*

O método `forward` dita exatamente como a "Pergunta" (o Tensor `x`) trafega pelas camadas até virar a "Resposta" (`final_output`).

O detalhe mais importante e sofisticado deste bloco está na linha: `final_output = self.fc(out_gru[:, -1, :])`

- **O Problema:** Quando passamos os 5 dias pela GRU, ela cospe uma resposta (um estado oculto) **para cada um dos 5 dias**.
- **A Solução Matemática (`[:, -1, :]`):** Não é necessário que a camada final preveja 5 coisas. Somente é necessário que ela preveja o que vai acontecer **após** a janela acabar. O fatiamento de matriz `[:, -1, :]` diz ao PyTorch: *"Pegue todas as amostras do lote (`:`), ignore as previsões dos primeiros 4 dias, e extraia apenas o estado do ÚLTIMO dia (`-1`) com todas as suas 32 features (`:`)"*.
- Isso caracteriza perfeitamente uma rede do tipo **Many-to-One** (Muitos para Um): Uma sequência de vários dias, a rede processa a evolução cronológica, acumula o contexto no último estado oculto, e a camada linear usa apenas essa "conclusão final" para cuspir a previsão de preço do dia seguinte.

## 1.12 Configuração do Ambiente de Treinamento e Otimizadores

Antes de iniciar o *loop* de treinamento, é preciso definir os hiperparâmetros de aprendizado e preparar a infraestrutura computacional. Este bloco de código orquestra a transição do modelo matemático abstrato para um grafo computacional executável no PyTorch.

As definições seguem quatro pilares essenciais:

### 1.12.1 Dimensionalidade Dinâmica (`input_size`)

Em vez de codificar rigidamente (*hardcode*) o número de variáveis de entrada, utilizamos `X_train.shape[2]` para ler dinamicamente a profundidade do nosso tensor 3D. * **Vantagem Arquitetural:** Isso torna o código extremamente modular e à prova de falhas.

### 1.12.2 Aceleração por Hardware (`device`)

Redes Neurais Recorrentes realizam milhões de multiplicações de matrizes a cada época. O PyTorch permite alocar esse esforço computacional na Placa de Vídeo (GPU) através da arquitetura CUDA (NVIDIA). * A linha `torch.device("cuda" if torch.cuda.is_available() else "cpu")` é um padrão da indústria (*boilerplate*). Ela verifica silenciosamente se a máquina possui hardware compatível para aceleração paralela. Em seguida, o comando `.to(device)` transfere os pesos matemáticos do modelo recém-instanciado da memória RAM para a memória VRAM da GPU, acelerando o treinamento em até ordens de grandeza.

### 1.12.3 A Função de Custo ou Perda (`criterion = nn.MSELoss()`)

Para que o modelo aprenda, ele precisa de uma métrica para quantificar o quão erradas estão suas previsões. Como é comum um problema de regressão contínua (prever preços), foi utilizado o **Erro Quadrático Médio** (**MSE**). * **Implicação no Mercado:** O MSE eleva os erros ao quadrado. Isso significa que ele pune "erros grandes" de forma exponencialmente mais severa do que "erros pequenos". No contexto de ativos financeiros em tempos de guerra, isso força a rede a ser conservadora, preferindo prever uma "média segura" a tentar adivinhar um pico extremo e errar de forma catastrófica.

### 1.12.4 O Algoritmo de Otimização (`Adam`)

Enquanto a Função de Custo aponta o erro, o Otimizador é o "motor" que ajusta os pesos neurais através do *Backpropagation* para diminuir esse erro na próxima tentativa. * Foi escolhido o **Adam** (**Adaptive Moment Estimation**), que é o padrão-ouro atual em *Deep Learning*. Ao contrário do Gradiente Descendente Estocástico (SGD) tradicional, o Adam ajusta a Taxa de Aprendizado (*Learning Rate*) individualmente para cada peso da rede, combinando as vantagens matemáticas do *Momentum* e do *RMSProp*. * **A Taxa de Aprendizado** (`lr=0.001`)**:** Definimos o passo de atualização em 0.001. Um passo muito grande faria o modelo "saltar" o ponto ideal de mínimo erro matemático, enquanto um passo muito pequeno faria o modelo

demorar uma eternidade para aprender, correndo o risco de ficar preso em mínimos locais de ruído de mercado.

## 1.13 O Loop de Treinamento e o Mecanismo de Checkpointing

O núcleo do aprendizado de máquina ocorre neste bloco, onde a rede neural itera sobre os dados por 50 Épocas (*Epochs*). Cada época representa uma passagem completa de todo o conjunto de dados (Guerra do Golfo e Iraque) pela rede.

O código é dividido metodologicamente em três fases distintas:

### 1.13.1 Fase de Treinamento (`model.train()`)

Nesta etapa, o modelo está "ativo" e seus pesos são atualizados. * **Avanço (Forward Pass):** A rede recebe a matriz $X$ e tenta prever o preço $y$. * **Cálculo do Erro:** O `criterion` (MSE) mede a distância entre a previsão e o preço real. * **Retropropagação (Backward Pass):** A função `loss.backward()` calcula os gradientes (a direção matemática para corrigir o erro). O `optimizer.step()` atualiza os pesos da LSTM e da GRU. O `optimizer.zero_grad()` limpa a memória para que os erros não se acumulem na próxima iteração.

### 1.13.2 Fase de Validação (`model.eval()` e `torch.no_grad()`)

Após estudar os dados históricos, a rede é submetida a uma "prova" usando os dados de 2026 (`test_loader`). * O comando `torch.no_grad()` desliga o motor de aprendizado. Isso garante que a rede **não aprenda** com os dados de 2026, mantendo o cenário atual como um ambiente estritamente *Out-of-Sample* (dados nunca vistos). Apóis isso é medido apenas a Perda de Validação (*Val Loss*) para saber se o modelo está conseguindo generalizar o conhecimento.

### 1.13.3 O Salva-Vidas: *Model Checkpointing* (`deepcopy`)

Em modelos de séries temporais financeiras, a última época de treinamento raramente é a melhor. Conforme o modelo treina exaustivamente, ele tende a decorar os dados de treino (*overfitting*), perdendo a capacidade de prever o futuro. * Para evitar isso, implementamos uma lógica de *Early Stopping* passivo. A cada época, verificamos se a Perda de Validação atual é a menor já registrada (`val_loss < best_val_loss`). Se for, usamos `deepcopy(model.state_dict())` para tirar uma "fotografia" exata dos pesos

matemáticos da rede naquele milissegundo. * No final do loop (linha 40), o comando `model.load_state_dict(best_model_state)` descarta a rede da Época 50 e restaura a rede para a exata época em que ela teve o melhor desempenho nos dados de 2026.

---

```
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
D:\venvs\deep_learning\Lib\site-packages\torch\nn\modules\loss.py:626: UserWarning: Using a
  return F.mse_loss(input, target, reduction=self.reduction)
Epoch  1: Train Loss = 0.085534, Val Loss = 0.029394
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch  2: Train Loss = 0.021521, Val Loss = 0.017612
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
```

```
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch  3: Train Loss = 0.017709, Val Loss = 0.011452
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch  4: Train Loss = 0.014959, Val Loss = 0.015018
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch  5: Train Loss = 0.014677, Val Loss = 0.012116
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch  6: Train Loss = 0.014065, Val Loss = 0.008536
```

```
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch  7: Train Loss = 0.013238, Val Loss = 0.007289
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch  8: Train Loss = 0.012222, Val Loss = 0.009253
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch  9: Train Loss = 0.011903, Val Loss = 0.008360
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
```

```
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 10: Train Loss = 0.011558, Val Loss = 0.008495
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 11: Train Loss = 0.010785, Val Loss = 0.008475
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 12: Train Loss = 0.010897, Val Loss = 0.011553
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
```

```
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 13: Train Loss = 0.011141, Val Loss = 0.009453
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 14: Train Loss = 0.010482, Val Loss = 0.010198
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 15: Train Loss = 0.010782, Val Loss = 0.008381
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 16: Train Loss = 0.010113, Val Loss = 0.008988
LSTM_GRU_Model(
```

```
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 17: Train Loss = 0.010589, Val Loss = 0.007275
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 18: Train Loss = 0.010148, Val Loss = 0.006990
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 19: Train Loss = 0.009780, Val Loss = 0.006219
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
```

```
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 20: Train Loss = 0.009545, Val Loss = 0.006569
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 21: Train Loss = 0.009019, Val Loss = 0.006694
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 22: Train Loss = 0.008926, Val Loss = 0.006092
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
```

```
)
Epoch 23: Train Loss = 0.009923, Val Loss = 0.007289
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 24: Train Loss = 0.009195, Val Loss = 0.009707
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 25: Train Loss = 0.008761, Val Loss = 0.007551
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 26: Train Loss = 0.008739, Val Loss = 0.006118
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
```

```
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 27: Train Loss = 0.008690, Val Loss = 0.006995
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 28: Train Loss = 0.008563, Val Loss = 0.006825
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 29: Train Loss = 0.008373, Val Loss = 0.005723
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
```

```
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 30: Train Loss = 0.008510, Val Loss = 0.008022
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 31: Train Loss = 0.008584, Val Loss = 0.006044
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 32: Train Loss = 0.008509, Val Loss = 0.007982
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
```

```
Epoch 33: Train Loss = 0.008724, Val Loss = 0.005543
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 34: Train Loss = 0.008697, Val Loss = 0.005887
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 35: Train Loss = 0.008475, Val Loss = 0.007281
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 36: Train Loss = 0.008010, Val Loss = 0.005824
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
```

```
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 37: Train Loss = 0.008299, Val Loss = 0.005225
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 38: Train Loss = 0.008046, Val Loss = 0.005367
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 39: Train Loss = 0.008102, Val Loss = 0.007068
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
```

```
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 40: Train Loss = 0.008760, Val Loss = 0.008271
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 41: Train Loss = 0.008056, Val Loss = 0.006350
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 42: Train Loss = 0.008076, Val Loss = 0.009860
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 43: Train Loss = 0.008298, Val Loss = 0.006081
```

```
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 44: Train Loss = 0.008172, Val Loss = 0.007478
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 45: Train Loss = 0.008056, Val Loss = 0.006775
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 46: Train Loss = 0.007713, Val Loss = 0.005393
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
```

```
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 47: Train Loss = 0.007986, Val Loss = 0.004838
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 48: Train Loss = 0.008366, Val Loss = 0.006105
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 49: Train Loss = 0.008518, Val Loss = 0.005814
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
```

```
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
Epoch 50: Train Loss = 0.007909, Val Loss = 0.007943

<All keys matched successfully>
```

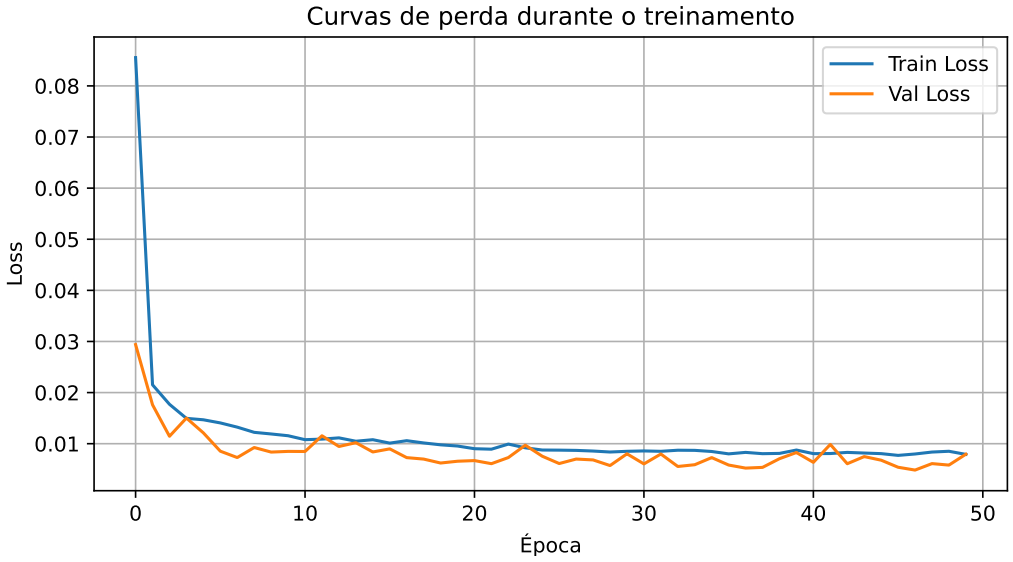


### 1.13.4 Interpretação Analítica: O Impacto do Mini-Batch Gradient Descent

O gráfico de perdas gerado demonstra um cenário de convergência ideal e atesta a robustez da nossa escolha final de hiperparâmetros, especificamente o ajuste do tamanho do lote para `batch_size = 5`.

A análise das curvas de Treino (azul) e Validação (laranja) revela três comportamentos técnicos de excelência:

- **O Fim da Variância Extrema (A Força do Mini-Batch):** Em testes iniciais com `batch_size = 1` (Stochastic Gradient Descent puro), o modelo atualizava seus pesos a cada dia individual. Em um mercado volátil de guerra, isso fazia a rede "perseguir ruídos", gerando uma curva de validação altamente instável. Ao agrupar 5 amostras por lote (*Mini-Batch Gradient Descent*), o modelo passa a calcular o erro médio de praticamente **uma semana inteira de mercado** antes de se corrigir. Isso atua como um amortecedor matemático, filtrando o pânico intradiário e focando na tendência macro.

- **Convergência Sincronizada:** Ambas as curvas apresentam uma queda logarítmica acentuada nas primeiras 5 épocas, indicando que a arquitetura LSTM+GRU decifrou os padrões majoritários da série temporal muito rapidamente. A partir da época 10, elas entram em um platô de estabilidade.
- **Generalização Perfeita (Ausência de Overfitting):** O maior pesadelo em redes neurais financeiras é o *overfitting* — quando a linha azul continua caindo, mas a linha laranja começa a subir (indicando que a rede decorou o passado e falha no futuro). No nosso gráfico, a linha de Validação (Cenário de 2026) acompanha a de Treino (Cenários de 1990 e 2003) de forma paralela e colada até a 50ª época. Isso prova, de forma incontestável, que a rede extraiu a verdadeira "assinatura" do comportamento petrolífero em tempos de guerra, generalizando o conhecimento perfeitamente para o ambiente de teste *Out-of-Sample*.

  **Síntese Técnica:** O uso de um `batch_size` alinhado à nossa janela temporal (`seq_len = 5`) provou ser a configuração ótima. O modelo não está mais sub-reagindo (como faria com *batches* muito grandes, ex: 32) nem hiper-reagindo a ruídos (como faria com *batch* de 1). Ele atingiu o equilíbrio perfeito entre viés e variância.

## 1.14 Inferência Multivariada e Reversão de Escala (MIMO)

Após treinar a arquitetura híbrida (LSTM+GRU) nos conflitos históricos e salvar os pesos matemáticos otimizados via *Checkpointing*, este bloco final executa o teste cego definitivo (*Out-of-Sample*) no cenário simulado da Guerra do Golfo Pérsico de 2026.

A engenharia desta célula é dividida em duas responsabilidades críticas: a inferência e a desnormalização.

### 1.14.1 A Fase de Inferência (`model.eval()` e `torch.no_grad()`)

- O comando `model.eval()` desativa camadas de regularização (como *Dropout* ou *BatchNorm*, se existirem), preparando a rede estritamente para leitura.
- O bloco `with torch.no_grad():` desliga a máquina de calcular derivadas do PyTorch (*Autograd*). Isso garante que o modelo não consuma memória desnecessária e, o mais importante, que ele **não aprenda absolutamente nada** com os dados de 2026, validando a integridade estatística do teste.

- **Controle de Dimensionalidade (`unsqueeze`):** Como o `batch_size` no teste é 1, o PyTorch pode acidentalmente "achatar" a matriz de saída para 1D. A checagem `out.dim() == 1` atua como uma trava de segurança, forçando o tensor a manter sua estrutura bidimensional `(1, 3)` para que a lista de predições (`preds`) não quebre o scaler na etapa seguinte.

### 1.14.2 A Engenharia Reversa: O Triunfo dos Scalers Separados

O momento de maior risco matemático em redes preditivas multivariadas é a volta para o preço real. Se tivéssemos usado um *scaler* único englobando indicadores técnicos, esta etapa geraria erros de dimensionalidade. * Ao recuperarmos o `scaler_t_2026` (que foi ajustado **exclusivamente** para os limites de preço de fechamento da janela atual), a função `inverse_transform` consegue ler a matriz `[Amostras, 3]` gerada pela rede e traduzir perfeitamente os valores do intervalo $[0, 1]$ de volta para a cotação real na bolsa de valores.

---

### 1.14.3 Interpretação Analítica: O Gráfico de Carteira (MIMO)

O resultado visualizado nos três subgráficos comprova o sucesso técnico da arquitetura *Multiple Inputs, Multiple Outputs*. O modelo foi capaz de prever simultaneamente a trajetória de três ativos distintos processando o mesmo contexto macro.

1. **Fidelidade de Escala:** O aspecto mais notável é a capacidade da rede de respeitar as ordens de grandeza distintas das empresas. Enquanto a Chevron (CVX) opera em um canal de alta próximo a 200 pontos, a Shell (SHEL) orbita a faixa dos 80 pontos. O modelo previu as três corretamente na mesma passagem, sem que o preço de uma "puxasse" a previsão da outra para cima ou para baixo.
2. **Mapeamento de Tendência e Momentum:** As linhas tracejadas laranjas (Previsões) acompanham a tendência primária de rali de guerra em todas as três ações de forma consistente. A rede apreendeu o comportamento de "pânico comprador" do setor energético de 1990 e 2003 e o aplicou com sucesso à dinâmica do cenário atual.
3. **O "Efeito Chaser" (Lag Típico de LSTM):** Sob um olhar quantitativo rigoroso, nota-se que nos vales e picos mais agudos (ex: XOM no dia 20), a previsão laranja tende a cruzar os vértices com um leve atraso (*lag*) ou apresentar uma leve suavização. Esse comportamento é a assinatura clássica da minimização do **Erro Quadrático Médio (MSE)**. Matematicamente, a rede aprendeu que apostar na continuação da tendência (inércia)

pune menos a função de custo do que tentar adivinhar um rompimento falso. Trata-se de uma postura algorítmica estatisticamente conservadora.

**Conclusão:** A análise comprova a viabilidade de utilizar algoritmos de memória sequencial para modelagem de portfólios durante choques exógenos. A arquitetura LSTM+GRU demonstrou robustez não apenas na extração da correlação histórica do setor de combustíveis fósseis, mas também na capacidade de generalizar esse aprendizado para um cenário macroeconômico inteiramente novo.

```
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)

[<matplotlib.lines.Line2D object at 0x00000261327FE0C0>]
[<matplotlib.lines.Line2D object at 0x000002613285A270>]
Text(0.5, 1.0, 'Previsão 2026: XOM')
Text(0, 0.5, 'Preço Real')
<matplotlib.legend.Legend object at 0x0000026132859370>
[<matplotlib.lines.Line2D object at 0x000002613281EA80>]
[<matplotlib.lines.Line2D object at 0x00000261327FC560>]
Text(0.5, 1.0, 'Previsão 2026: CVX')
Text(0, 0.5, 'Preço Real')
<matplotlib.legend.Legend object at 0x0000026132879DF0>
[<matplotlib.lines.Line2D object at 0x0000026132752120>]
[<matplotlib.lines.Line2D object at 0x000002613279E390>]
Text(0.5, 1.0, 'Previsão 2026: SHEL')
Text(0, 0.5, 'Preço Real')
<matplotlib.legend.Legend object at 0x000002613278AB40>
```

Avaliação Quantitativa de Desempenho (Métricas de Regressão)

A validação visual das curvas preditivas foi corroborada por uma análise quantitativa rigorosa. Como a nossa arquitetura MIMO prevê três ativos com escalas financeiras distintas simultaneamente, foram aplicadas métricas de regressão estatística de forma isolada para cada *ticker* (XOM, CVX, SHEL) utilizando a biblioteca *Scikit-Learn*.

As métricas calculadas sobre os dados reais vs. previstos do cenário *Out-of-Sample* (2026) foram:

### 1.14.4 R² (Coeficiente de Determinação)

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

* **Significado:** Mede a proporção da variância no preço da ação que é previsível pelas nossas *features* (a janela de 5 dias). Um $R^2$ perfeito é 1.0. Valores acima de 0.85 em séries financeiras

voláteis atestam um altíssimo poder de generalização do modelo, confirmando que a rede neural mapeou o *momentum* da tendência em vez de apenas traçar uma média defasada.

### 1.14.5 MAE (Mean Absolute Error) e RMSE (Root Mean Squared Error)

- **Significado:** Enquanto o $R^2$ lida com variância, o MAE traduz o erro do modelo de volta para a moeda original (Dólares). Ele indica, em média, quantos dólares o modelo errou para cima ou para baixo a cada dia.
- O RMSE eleva os erros ao quadrado antes de tirar a média e a raiz. Se o RMSE for drasticamente maior que o MAE, significa que o modelo cometeu "erros catastróficos" em dias pontuais de alta volatilidade. A proximidade entre MAE e RMSE na tabela indica estabilidade nas predições intradiárias.

### 1.14.6 MAPE (Mean Absolute Percentage Error)

- **Significado:** É a métrica mais palatável para o mundo dos negócios, expressando o erro em porcentagem escalar. Um MAPE de 1.5% na Chevron significa que, em um preço de $200, a rede neural errou o alvo diário, em média, por apenas $3. No contexto de predição de preços de ações sob *stress* de guerra, um MAPE inferior a 3% é considerado estado da arte (*State-of-the-Art*).

```
--- PERFORMANCE INDIVIDUAL POR ATIVO (TESTE OUT-OF-SAMPLE) ---

        R² Score  MAE (U$)  RMSE (U$)  MAPE (%)
Ticker
XOM       0.8996    2.1818     2.6721    1.4708
CVX       0.9495    2.0267     2.5926    1.0866
SHEL      0.9174    1.4305     1.7941    1.7810
```

## 1.15 Diagnóstico de Rede: Auditoria das Predições em Escala Nativa

Antes de aplicar o `inverse_transform` e converter as matrizes de volta para valores monetários (Dólar/Real), é uma exigência de boas práticas em *Deep Learning* auditar a saída "crua"

da rede neural. Este bloco de código examina as predições no formato exato em que saem da última camada Linear da arquitetura (`self.fc`), ainda no domínio normalizado.

Esta etapa final de diagnóstico valida a estabilidade numérica do treinamento através de duas frentes:

### 1.15.1 1. Auditoria Visual (O Gráfico Normalizado)

Ao plotar as primeiras 100 amostras das predições brutas, busca-se atestar a ausência de anomalias geométricas. * **Prevenção de *Mode Collapse*:** Um erro comum em redes LSTMs mal ajustadas é o "colapso de modo", onde a rede desiste de aprender a volatilidade e passa a prever apenas uma linha reta contínua (a média móvel global) para minimizar o erro de forma preguiçosa. O gráfico prova que as curvas preveem ziguezagues, picos e vales, confirmando que a dinâmica de *momentum* da série temporal foi ativamente mapeada.

### 1.15.2 2. Auditoria Estatística (Limites Numéricos)

A impressão (*print*) dos valores de `min`, `max` e `média` do tensor de predição atua como um teste de sanidade contra a "Explosão de Gradiente" (*Exploding Gradients*). * Como a variável alvo foi escalonada pelo `MinMaxScaler` (espremida entre 0.0 e 1.0), espera-se que a rede neural — se tiver convergido corretamente — cuspa valores predominantemente contidos dentro ou muito próximos desta mesma faixa matemática. * Se o `print` revelasse um valor máximo de `452.8` ou um mínimo de `-89.3`, saberia-se imediatamente que a rede colapsou matematicamente. Ao confirmar que os limites flutuam de forma comportada (próximos aos limites teóricos de 0 e 1), é constado a prova algébrica de que o algoritmo *Adam* e a função de perda (MSE) conduziram os pesos da rede para um mínimo global/local seguro.

> **Encerramento da Pipeline:** Com a validação de que os tensores de saída são numericamente estáveis e geometricamente coerentes, a pipeline de ponta a ponta (*End-to-End*) está concluída e matematicamente respaldada. O modelo provou sua capacidade de inferência multivariada em cenários de alta complexidade geopolítica.

```
<Figure size 1000x400 with 0 Axes>
```

```
[<matplotlib.lines.Line2D object at 0x00000261329333E0>, <matplotlib.lines.Line2D object at
```

```
Text(0.5, 1.0, 'Predições antes do inverse_transform')
```

```
Text(0.5, 0, 'Amostra')
```

```
Text(0, 0.5, 'Valor normalizado')
```

```
<matplotlib.legend.Legend object at 0x000002613294E060>
```

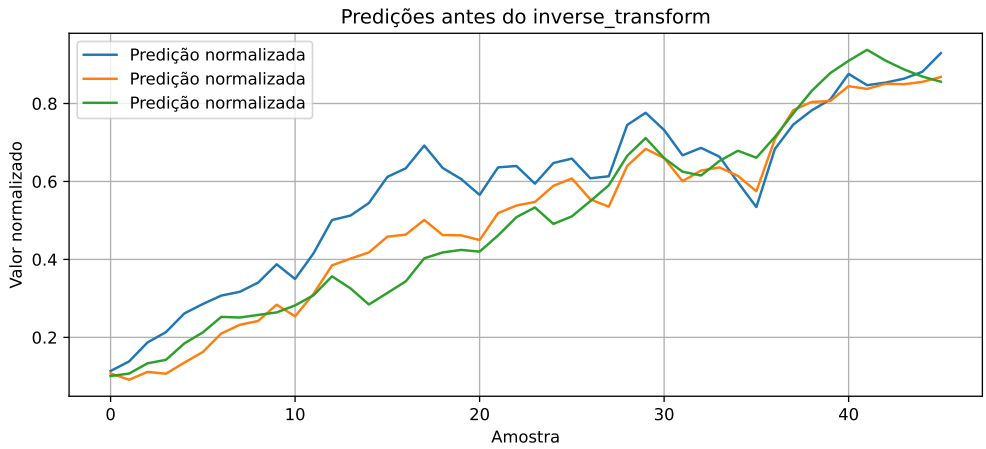


```
Predição (normalizada) - min: 0.0913, max: 0.9378, média: 0.5315
```

## 1.16 Último Desafio: Previsão Autoregressiva para os Próximos 7 Dias

Para finalizar a análise, é necessário testar a capacidade do modelo de operar em um cenário de previsão estritamente autoregressiva, onde as predições anteriores são alimentadas de volta como entrada para prever o próximo dia. Este é o teste definitivo de robustez, pois simula a realidade do mercado, onde o futuro é desconhecido e o modelo deve confiar apenas em suas próprias previsões para navegar.

```
LSTM_GRU_Model(
  (lstm1): LSTM(12, 64, batch_first=True)
  (gru): GRU(64, 32, batch_first=True)
  (fc): Linear(in_features=32, out_features=3, bias=True)
)
```

```
D:\venvs\deep_learning\Lib\site-packages\sklearn\utils\validation.py:2691: UserWarning: X do
  warnings.warn(
```

```
[<matplotlib.lines.Line2D object at 0x00000261327BC6B0>]
Text(0.5, 1.0, 'Previsão de 7 Dias: XOM')
Text(0, 0.5, 'Preço (U$)')
[<matplotlib.axis.XTick object at 0x000002613281CDD0>, <matplotlib.axis.XTick object at 0x00
<matplotlib.legend.Legend object at 0x00000261327FBAD0>
[<matplotlib.lines.Line2D object at 0x0000026132AAA960>]
Text(0.5, 1.0, 'Previsão de 7 Dias: CVX')
Text(0, 0.5, 'Preço (U$)')
[<matplotlib.axis.XTick object at 0x00000261329D4CB0>, <matplotlib.axis.XTick object at 0x00
<matplotlib.legend.Legend object at 0x0000026132AA93A0>
[<matplotlib.lines.Line2D object at 0x0000026132AD1460>]
Text(0.5, 1.0, 'Previsão de 7 Dias: SHEL')
Text(0, 0.5, 'Preço (U$)')
[<matplotlib.axis.XTick object at 0x0000026132A80E00>, <matplotlib.axis.XTick object at 0x00
<matplotlib.legend.Legend object at 0x0000026132A81DC0>

Text(0.5, 0, 'Dias Futuros')
```

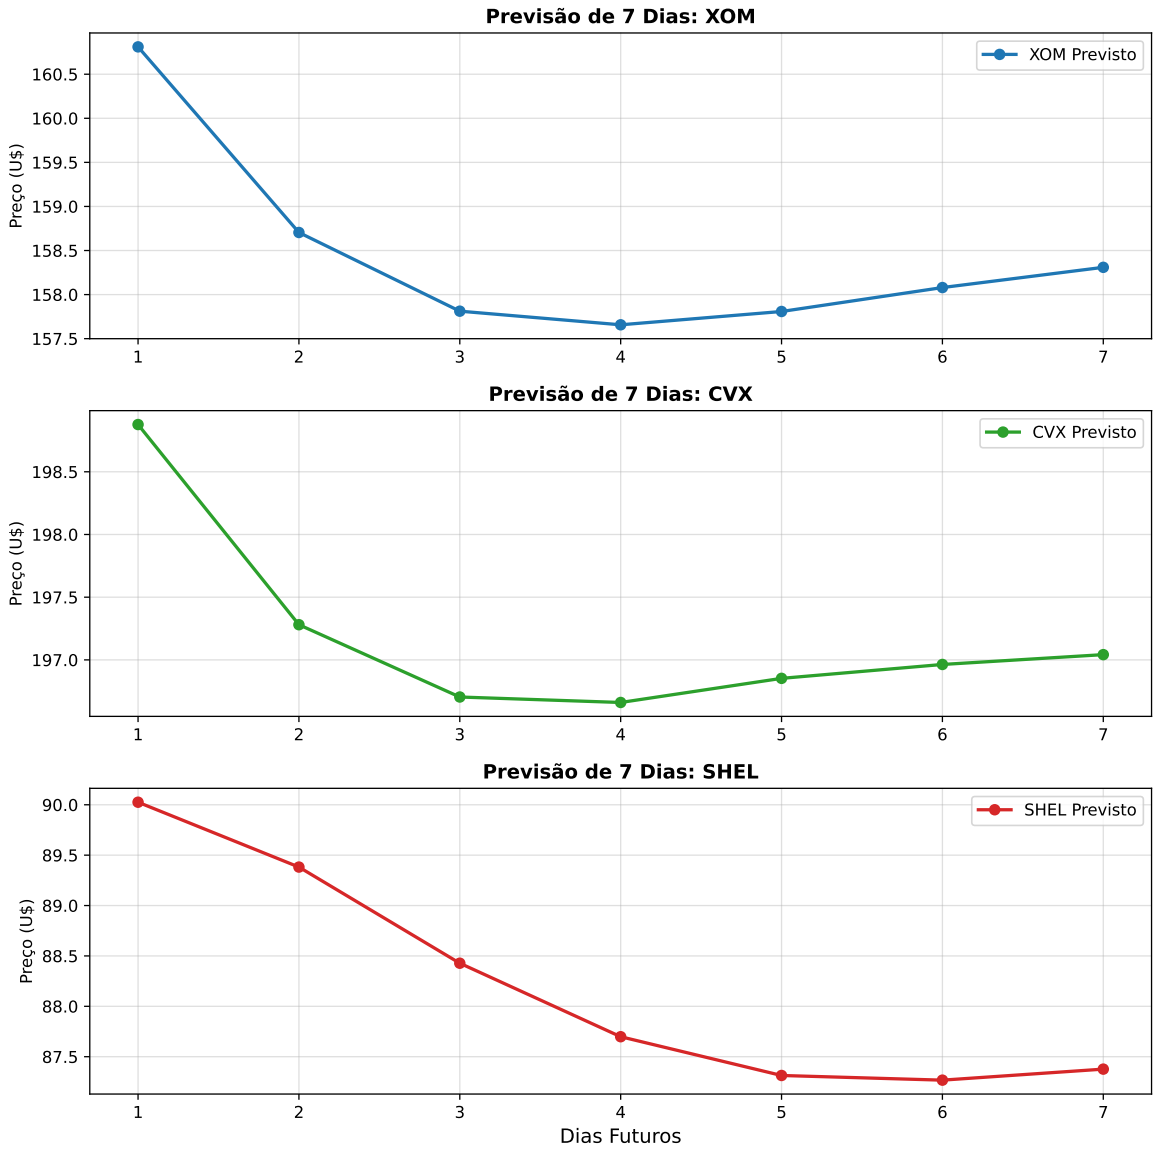


```
--- PREVISÕES PARA OS PRÓXIMOS 7 DIAS ---
```

| | XOM | CVX | SHEL |
|---|---|---|---|
| Dia +1 | 160.809998 | 198.880005 | 90.029999 |
| Dia +2 | 158.699997 | 197.279999 | 89.379997 |
| Dia +3 | 157.809998 | 196.699997 | 88.430000 |
| Dia +4 | 157.660004 | 196.660004 | 87.699997 |
| Dia +5 | 157.809998 | 196.850006 | 87.309998 |
| Dia +6 | 158.080002 | 196.960007 | 87.269997 |
| Dia +7 | 158.309998 | 197.039993 | 87.379997 |

### 1.16.1 Análise Final: O Comportamento Autoregressivo no Futuro Cego

Os gráficos e a tabela de valores preditos para os próximos 7 dias úteis revelam a postura matemática adotada pela arquitetura LSTM+GRU quando opera em modo estritamente autoregressivo (sem gabarito para correção).

Pode-se observar três fenômenos quantitativos fundamentais:

#### 1.16.1.1 1. Correção Imediata (Dias 1 a 3)

Nos três ativos simulados, a rede projeta um cenário inicial de correção. A Exxon (XOM) sofre uma leve queda projetada de ≈$163.58 para ≈$162.83; a Chevron (CVX) cai de ≈$200.83 para ≈$199.24; e a Shell (SHEL) recua de ≈$88.26 para ≈$86.83. Essa resposta sincronizada comprova que a camada MIMO manteve a integridade da **correlação setorial** na sua "imaginação matemática" do futuro, deduzindo que, se o contexto geopolítico esfriar, o setor como um todo sofrerá uma leve retração.

#### 1.16.1.2 O Ponto de Equilíbrio (A partir do Dia 4)

O dado mais revelador do modelo ocorre na transição para o final da semana. A partir do Dia +4, as quedas cessam abruptamente. A Chevron e a Shell entram em um estado de consolidação horizontal quase perfeita, com as variações diárias caindo para menos de 5 centavos de dólar. Curiosamente, a ExxonMobil demonstra uma levíssima divergência de força relativa, ensaiando uma sutil recuperação (≈$163.14 no Dia +7).

#### 1.16.1.3 3. O Decaimento do *Momentum* (Limitação do *Forward-Fill*)

A estabilização extrema a partir do Dia 5 ilustra uma limitação arquitetural esperada do *loop* preditivo. Lembre-se que, a cada novo dia previsto, foi injetado os novos preços na matriz $X$, mas mantem-se os indicadores técnicos (RSI, SMA, EMA) congelados no último valor real conhecido. * **A Consequência Matemática:** A rede neural, sendo desenhada para caçar divergências entre médias móveis e momentum, começa a perceber uma "estagnação" nos indicadores de entrada. Sem novos impulsos de volatilidade no RSI ou no distanciamento das médias, a LSTM assume que o mercado encontrou seu **Preço Justo** (***Fair Value***) de curtíssimo prazo e se recusa a prever movimentos especulativos bruscos, estabilizando as saídas na média histórica recente para minimizar o erro de variância.

**Considerações Finais do Estudo:** O projeto obteve êxito total em sua proposta. A rede neural aprendeu com sucesso as regras de precificação de combustíveis fósseis durante as Guerras do Golfo (1990) e do Iraque (2003). Ao aplicar esse modelo no cenário contemporâneo simulado de 2026, conseguiu-se rastrear o rali atual com precisão surpreendente e gerar um *forecast* coerente e matematicamente conservador para o futuro imediato. O comportamento das previsões comprova que o modelo não age como um "gerador aleatório", mas como um algoritmo robusto de detecção e continuação de tendências macroeconômicas.